

Active Learning в рекомендательных системах

План

1

Что такое Active Learning

2

Когда нужно использовать Active Learning

3

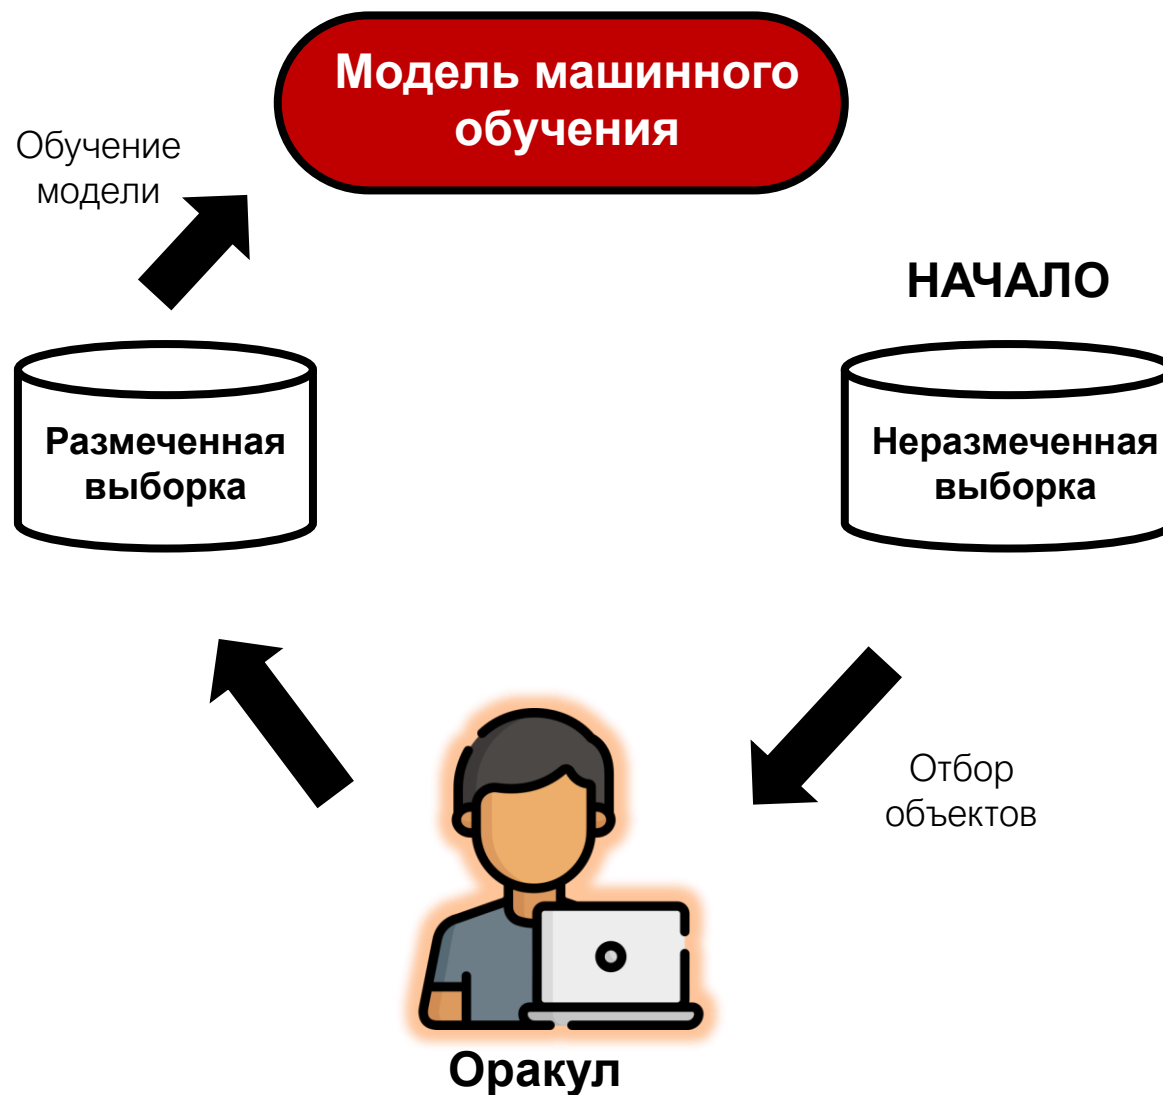
Применение Active Learning в рекомендательных системах

Что такое Active Learning

Active Learning

Активное обучение

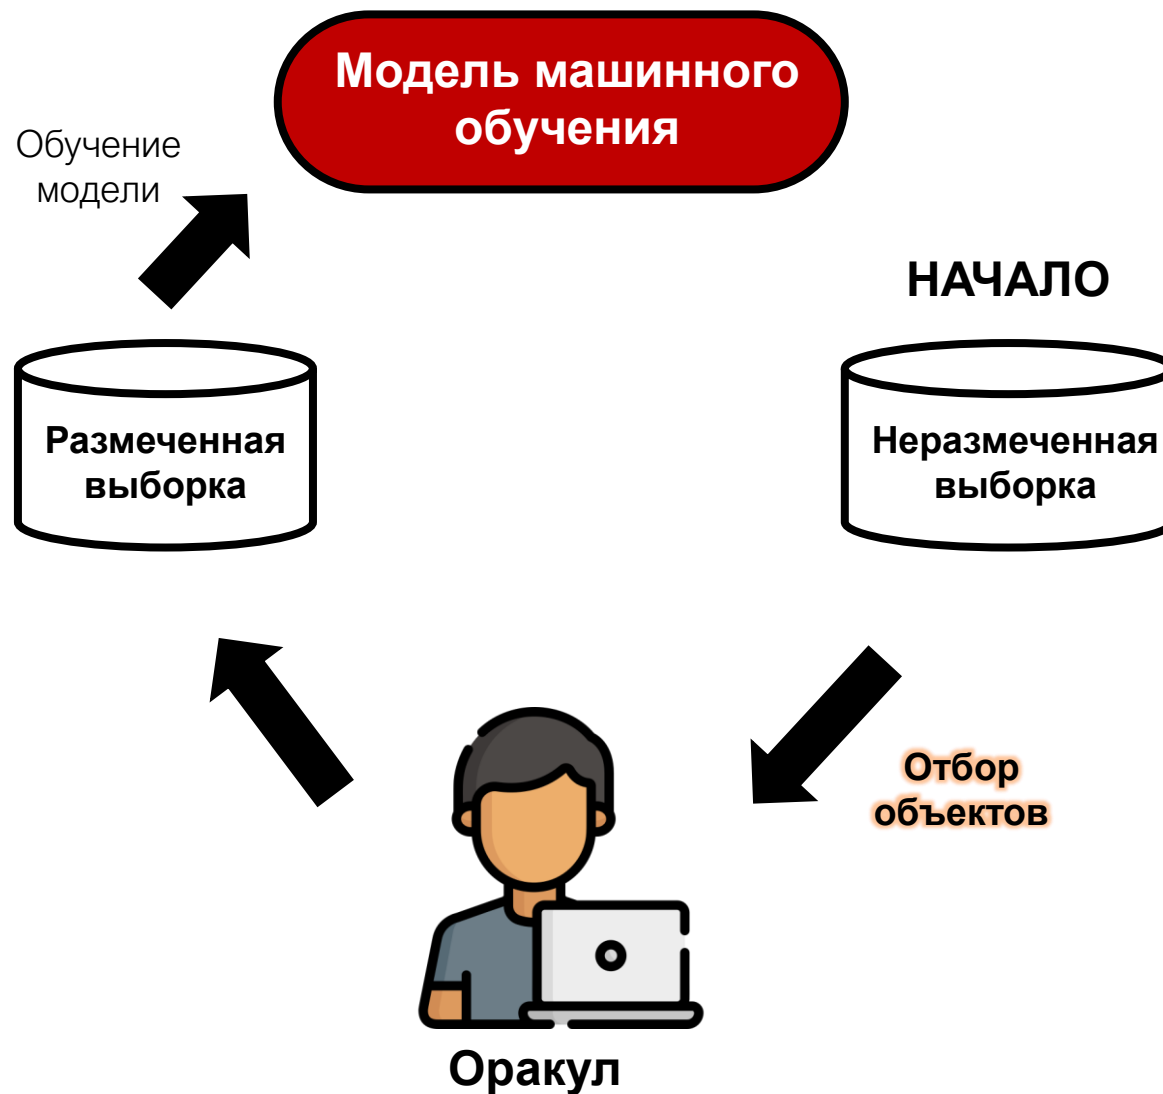
(англ. active learning) — область машинного обучения, где алгоритм взаимодействует с некоторым источником информации, или **оракулом**, способным размечать запрошенные данные.



Active Learning

Важная задача активного обучения – **отбор объектов**.

Это выбор тех объектов, которые следует отправить оракулу для получения достоверной информации об их классификации. От грамотности отбора зависит время работы алгоритма, качество классификации и затраты на внешние ресурсы.



Постановка задачи



Дано множество неразмеченных данных:

$$X = \{x_1, \dots, x_n\}$$

Множество меток:

$$Y = \{y_1, \dots, y_m\}$$

Оракул:

$O: X \rightarrow Y$ – функция, которая по объекту возвращает его метку

Требуется восстановить функцию $a: X \rightarrow Y$ минимизируя количество обращений к оракулу

Постановка задачи



На каждой итерации алгоритм фиксирует три множества:

$X_{unlabeled}$ — множество еще не размеченных объектов

$X_{labeled}$ — множество размеченных

X_{query} — множество объектов, которые подаются на вход оракулу. Заметим, что не всегда $X_{query} \subset X_{unlabeled}$, поскольку алгоритм может сам синтезировать объекты.

Постановка

$$\sum_{i=1}^n C_i \cdot L(b; x_i, y_i) \rightarrow \min_b$$

L – это некоторый функционал качества. Например MSE.

b – параметры модели, которые нужно восстановить.

$C_i = C_i(x_i, y_i)$ - стоимость получения пары (x_i, y_i) . В общем случае стоимость может быть случайной.

Стратегии (теория)

Отбор объектов из выборки (pool-based active learning).

Имеется некоторая выборка, и алгоритм использует объекты (X) из нее в качестве запросов к оракулу, чтобы получить разметку (Y). В данной стратегии каждому объекту присваивается степень информативности — сколько выгоды принесет информация об истинной метке объекта, и оракулу отправляются самые информативные объекты.

Стратегии (теория)

Отбор объектов из потока (selective sampling)

Алгоритм пользуется не статической выборкой, а потоком данных, и для каждого объекта из потока принимается решение, запрашивать оракула на этом объекте или нет. В случае, если принято решение запросить оракула, объект и его метка используются в дальнейшем обучении модели, в противном случае объект просто отбрасывается. В отличие от отбора объектов из выборки отбор из потока не строит никаких предположений насчет плотности распределения объектов, не хранит сами объекты и работает значительно быстрее.

Стратегии (теория)

Синтез объектов (query synthesis)

Вместо использования заранее заданных объектов, алгоритм сам выбирает объекты (X) и подает их на вход оракулу (Y). Например, если объекты — это вектора в n -мерном пространстве, разделенные гиперплоскостью и решается задача бинарной классификации, имеет смысл давать оракулу на вход синтезированные вектора, близкие к границе.

Методы AL



Метод обучения на примерах

Метод выбора обучающих примеров этого типа выбирает точки, основанные на их свойствах, в попытке предсказать рейтинги пользователя, находя наиболее близкое соответствие с другими пользователями в системе, без явного знания базовой модели. Другие общие названия этого типа включают основанное на памяти, ленивое обучение (lazy learning).

Методы AL

Групповые и последовательные методы (Sequential and Batch Models)

Поскольку обычно пользователи хотят, чтобы система сразу же выводила что-то интересное, общий подход заключается в последовательном пересчете прогнозируемых оценок пользователей после того, как они оценили один элемент. Однако также можно разрешить пользователю оценивать несколько элементов или несколько функций элемента перед изменением модели.

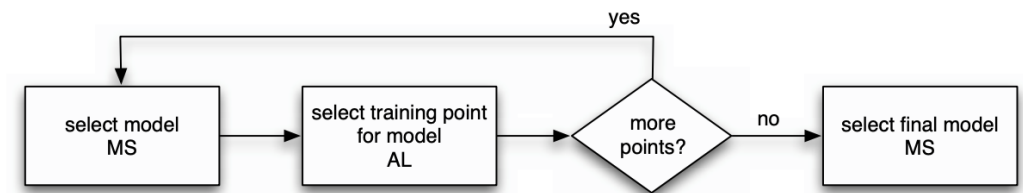


Fig. 23.11: Sequential Active Learning.

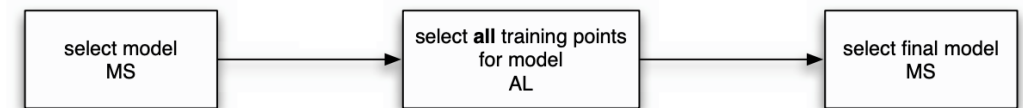


Fig. 23.12: Batch Active Learning.

Свойства данных



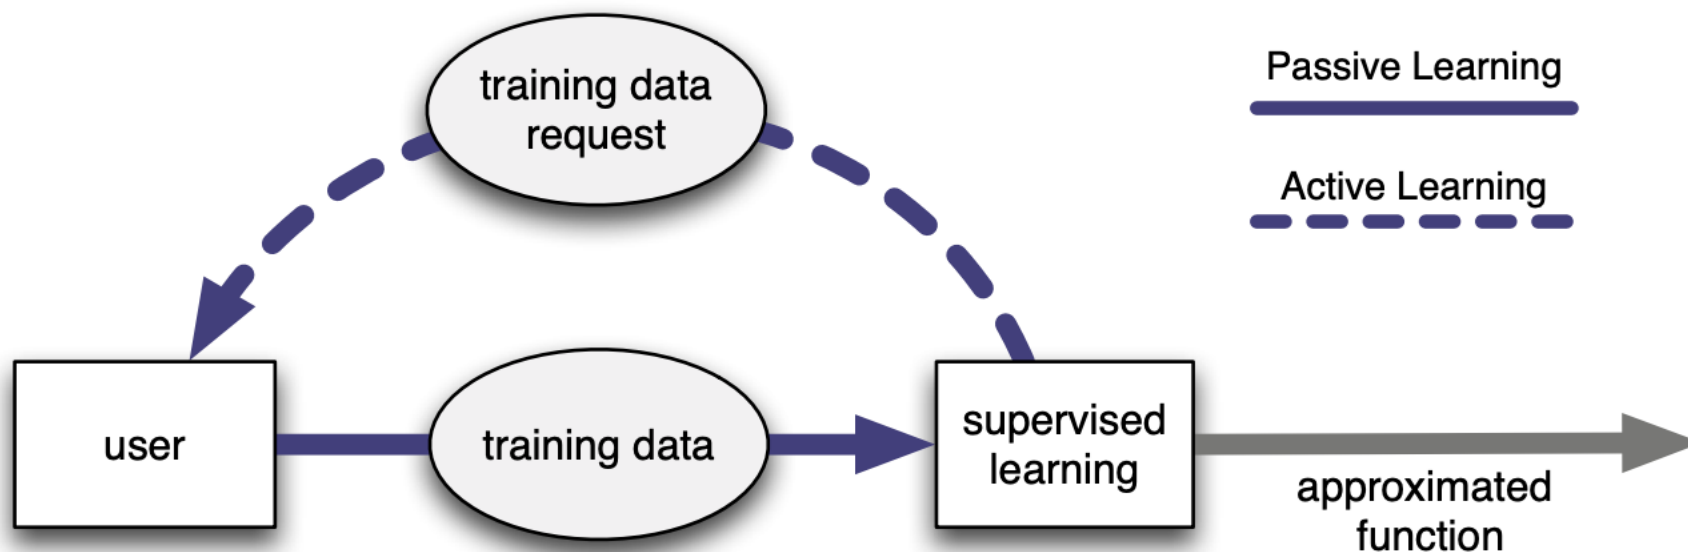
Три фактора для максимизации эффективности:

(R1) Represented: представлено ли оно уже существующим обучающим набором?

(R2) Representative: Является ли точка хорошим выбором для представления других точек данных? Или это выпадающая точка?

(R3) Results: приведет ли выбор этой точки к повышению рейтингов прогнозов или выполнению другой цели?

Отличие Active Learning от Passive Learning



Активное обучение использует **интерактивный / итеративный процесс** для получения обучающих данных, в отличие от пассивного обучения, когда данные просто предоставляются.

Когда нужно использовать Active Learning

Использование AL в рекомендательных системах



- Рекомендательные системы часто имеют неопределенную или неограниченную цель, а именно прогнозировать элементы, которые могут заинтересовать пользователя.
- Поэтому AL старается максимально сократить пространство поиска и быстро найти то, что ищет пользователь

Цели использования



- При активном обучении системе не требуется доступ ко всем данным, и вместо этого она может итеративно получать дополнительные данные
- Активное обучение позволяет системе тщательно анализировать доступные данные и решать, какие данные следует собирать. Этот процесс не позволит собирать зашумленные данные и может улучшить качество входных данных.

Когда нужно использовать AL?



- Проблема с новым пользователем
- Проблема нового продукта
- **Когда можно нивелировать стоимость**
- Адаптация к различным методам AL

Проблема с новым пользователем



- Когда пользователь начинает использовать рекомендательные системы, он ожидает получить интересные результаты после минимального времени обучения.
- Хотя система мало знает о предпочтениях пользователя, важно, чтобы обучающие баллы выбирались для оценки пользователем, что позволит максимально понять, чего хочет новый пользователь

Проблема нового продукта



- По мере того, как в систему вводятся новые продукты, важно быстро повышать точность прогнозов для этих элементов, выбирая пользователей для их оценки.

Стоимость получения выходного значения



- Различные способы получения выходного значения имеют разные затраты. Неявные стратегии, такие как обработка клика пользователя по предлагаемому элементу как положительного результата или отказ от клика как отрицательного результата, являются недорогостоящими по отношению к усилиям пользователя.
- И наоборот, просьба к пользователю явно оценить элемент обходится дороже, хотя по-прежнему зависит от задачи.

Адаптация к различным методам AI



- Хотя мы фокусируемся на традиционной цели уменьшения ошибки прогнозирования, не менее правдоподобно создание метода для максимизации других целей, таких как прибыльность. В этом случае модель выбрала бы точки, которые, скорее всего, увеличивают прибыль, а не точность рейтинга.

Применение Active Learning в рекомендательных системах

Регрессия и классификация




Проблема прогнозирования оценок пользователя может рассматриваться **как проблема регрессии и классификации.**

Это проблема регрессии, поскольку рейтинги представляют собой дискретные числовые значения, например.

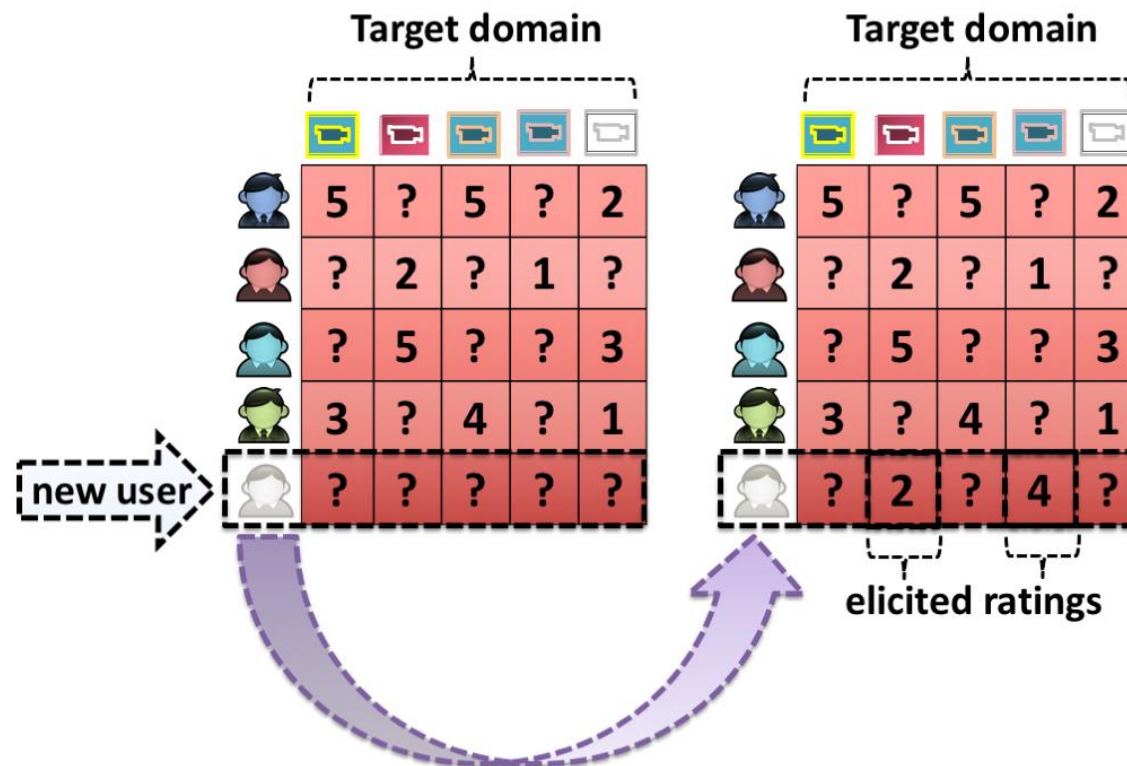
С другой стороны, мы можем игнорировать числовые свойства рейтингов и рассматривать проблему как классификационную, рассматривая рейтинги как классы/метки.

Пример AL в рекомендательных системах



Пример AL в рекомендательных системах

Новый пользователь регистрируется в системе, где алгоритм AL предлагает ей оценить выбор элементов и выставляет оценки.



Uncertainty-based Active Learning

AL на основе неопределенности пытается получить обучающие точки, чтобы уменьшить неопределенность в некоторых аспектах, например, в отношении выходных значений, параметров модели, границы принятия решения и т. д.

$$P(Y_x = y) = \frac{\sum_{nn \in NN_{x,y}} w_{nn}}{\sum_{nn \in NN_x} w_{nn}}$$

NN_x - соседи, которые оценили элемент x


$NN_{x,y}$ - соседи, которые присвоили элементу x рейтинг y

w_{nn} - вес соседа .

Сэмплирование по неопределенности

Основная идея: брать объект, с наибольшей неопределенностью.
В качестве критерия:

- Наименьшей достоверности
- Наименьшей разности отступов
- Максимум энтропии



Сэмплирование по неувверенности

Аналог для регрессии:

- 1) Переформулировать в виде многоклассовой классификации. И см. выше.
- 2) Брать объект с самым широким доверительным интервалом.

Измерение Uncertainty

- Через дисперсию:

$$Uncertainty(Y_a) = VAR(Y_a) = \sum_{y \in Y} (y - \bar{Y}_a)^2 P(Y_a = y)$$

- Через энтропию:

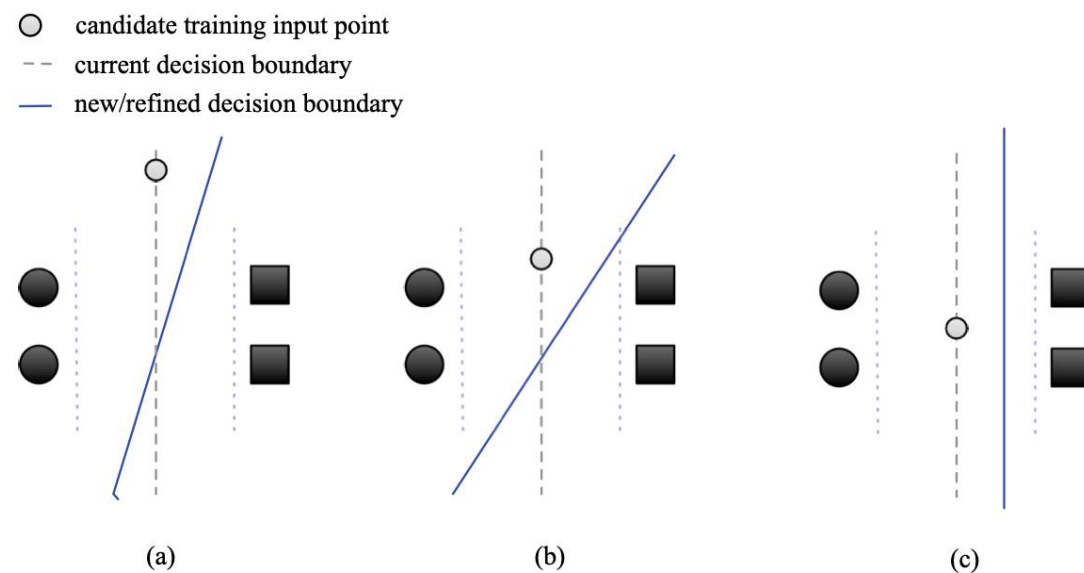
$$Uncertainty(Y_a) = ENT(Y_a) = - \sum_{y \in Y} P(Y_a = y) \log P(Y_a = y)$$

- Через вероятности наиболее вероятного рейтинга:

$$Uncertainty(Y_a) = -P(Y_a = y^*)$$

Decision Boundary Uncertainty

В методах, основанных на границах принятия решений (decision boundary uncertainty), обучающие точки выбираются так, чтобы улучшить границы принятия решений. Часто считается, что существующая граница принятия решения является в некоторой степени точной, поэтому точки отбираются близко к границе решения для дальнейшего ее уточнения.



Error-based Active Learning



Методы активного обучения, основанные на ошибках, направлены на уменьшение ошибки прогнозирования, которая часто является конечной целью. **Подходы на основе примеров** пытаются найти и использовать связь между входными точками обучения и ошибкой прогноза. **Подходы, основанные на моделях**, как правило, направлены на уменьшение ошибки модели (т. е. Ошибки параметров модели), что, как ожидается, приведет к улучшению ошибки прогнозирования.

Методы на основе примеров

Output Estimates Change

$$\hat{G}_{Y_{change}}(x_a) = - \sum_{x \in X^{(test)}} \mathbb{E}_{y \in Y} \mathcal{L} \left(\hat{f}_{\mathcal{T}}(x), \hat{f}_{\mathcal{T} \cup (x_a, y)}(x) \right)$$

$$\hat{G}_{Y_{change}}(x_a) = - \sum_{x \in X^{(test)}} \frac{1}{|Y|} \mathbb{E}_{y \in Y} \left(\hat{f}_{\mathcal{T}}(x), \hat{f}_{\mathcal{T} \cup (x_a, y)}(x) \right)^2$$

Методы на основе примеров

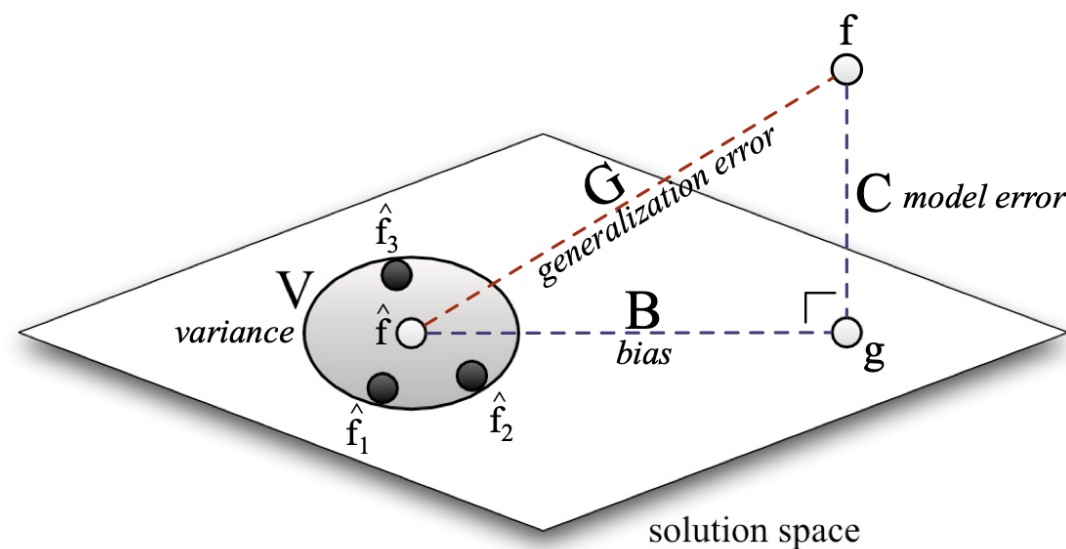
Cross Validation-based Active Learning

$$\hat{G}_{\text{CM}_{\mathcal{T}}}(x_a) = -\max_{y \in Y} \sum_{x \in X(\text{Train})} \mathcal{L}(\hat{f}_{\mathcal{T} \cup (x_a, y)}(x), f(x))$$

Методы на основе моделей

Parameter Change-based

$$\hat{G}_{\theta_{change}}(x_a) = - \sum_{\theta} \mathbb{E}_{y \in Y} \mathcal{L}(\theta_{\mathcal{T}}, \theta_{\mathcal{T} \cup (x_a, y)})$$



Методы на основе моделей

Variance-based

В этом подходе ошибка разбивается на три компонента: ошибка модели C (разница между приближением оптимальной функции g , заданной текущей модели и истинной функцией f), смещение B (разница между текущим приближением f и оптимальным одним g), а дисперсия V (насколько изменяется аппроксимация функции f).

$$G = C + B + V$$

Ensemble-based Active Learning



- Основанные на моделях (Model-based)
- Основанные на кандидатах (Candidates-based)

Ensemble-based Active Learning

Основанные на моделях (Model-based)

В подходах, основанных на моделях, модели образуют «комитет» моделей, которые действуют, в некотором смысле, совместно для выбора входных точек обучения. Методы, как правило, различаются в отношении:

1. того, как построить комитет моделей
2. как выбрать обучающие точки на основе членов комитета

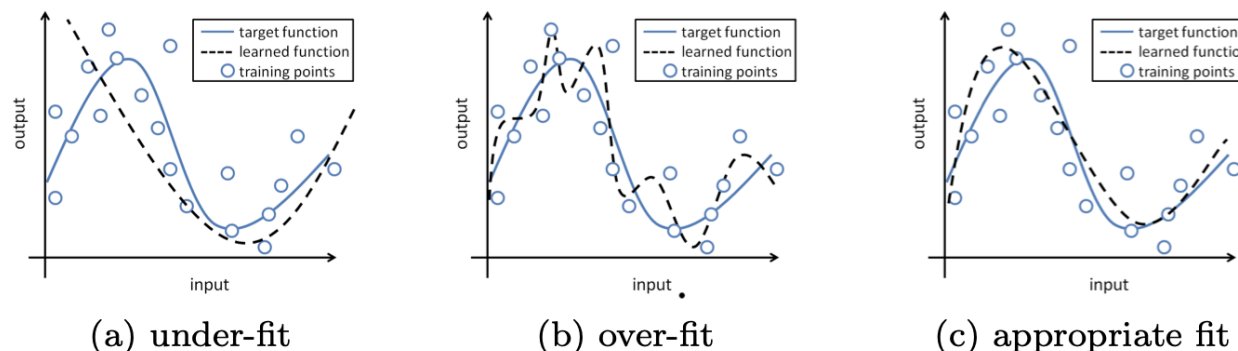


Figure 8: Dependence between model complexity and accuracy.

Ensemble-based Active Learning

Основанные на кандидатах (Candidates-based)

Цель выбора модели состоит в том, чтобы определить веса моделей в ансамбле или, в случае использования одной модели, выбрать подходящую:

$$\min_{\mathcal{M}} G(\mathcal{M})$$

$$\min_{X^{(Train)}} G(X^{(Train)})$$

$$\min_{X^{(Train)}} \sum_{\mathcal{M}} \hat{G}(X^{(Train)}, \mathcal{M}) \omega(\mathcal{M})$$





Figure 9: Training input points that are good for learning one model, are not necessary good for the other.



Unable to determine which model is more appropriate (Model Selection), until training points have been obtained (Active Learning).

Figure 10: Dependence of Model Selection on Active Learning.

Несогласие в комитете



Идея: у нас есть R алгоритмов выбираем x_i – где модели между собой максимально расходятся.

Что значит максимально расходятся?

- 1) Максимальная выборочная дисперсия
- 2) Максимальный размах (+интерквантильный)
- 3) ...

Conversation-based Active Learning



AL, *основанный на разговоре*, ориентирован на цель с задачей начать общий круг и, через серию циклов взаимодействия, сузить интересы пользователя до тех пор, пока не будет получен желаемый пункт.

- Case-based Critique
- Diversity-based
- Query Editing-based

Conversation-based Active Learning



Case-based Critique

Одним из средств ведения беседы с пользователем является подход на основе прецедентов, который находит случаи, похожие на запрос или профиль пользователя, а затем вызывает критику для уточнения интересов пользователя. На каждом этапе итерации рекомендации системы отображаются в ранжированном списке, что позволяет критиковать пользователей, что заставляет систему пересматривать свои рекомендации и генерировать новый ранжированный список.

Conversation-based Active Learning



Diversity-based

Если предлагаемые элементы слишком похожи друг на друга, они могут не соответствовать текущему пространству поиска. По сути, рекомендуемые элементы должны быть как можно более репрезентативными и разнообразными. Особенно важно обеспечить разнообразный выбор, пока предпочтения пользователя находятся в зачаточном состоянии. Как только пользователь узнает, чего он хочет, может оказаться уместным представление элементов, которые максимально соответствуют друг другу, и используемый метод AL должен попытаться провести это различие.

Conversation-based Active Learning



Query Editing-based

Возможность состоит в том, чтобы позволить пользователю многократно редактировать и повторно отправлять поисковый запрос, пока желаемый элемент не будет найден. Поскольку это итеративный процесс, цель состоит в том, чтобы минимизировать количество запросов, необходимых до того, как пользователь найдет элемент с наибольшей полезностью. Полезность запроса оценивается на основе вероятности того, что пользователь отправит конкретный запрос, наряду с его выполнимостью, что достигается путем наблюдения за действиями пользователя и вывода любых ограничений на пользовательские предпочтения, связанные с полезностью элемента и обновлением модели пользователя.

Стратегии обучения



- Uncertainty Reduction
- Error Reduction
- User Adaptation
- Acquisition Probability
- Decision Tree-based
- Prediction based
- Hybrid

Стратегии обучения



Uncertainty Reduction (Стратегии уменьшения неопределенности) пытаются выбрать элементы с более разнообразными оценками, поскольку система в них менее уверена. Предположим, что многие пользователи дали высокие оценки какому-либо элементу, в то время как многие пользователи дали низкие оценки тому же элементу. В таком случае системе будет сложно предсказать, рекомендовать или не рекомендовать этот товар. И наоборот, элемент, получивший низкие оценки почти всех пользователей, может быть легко исключен из рекомендации.

Следовательно, сбор оценок элементов с разными рейтингами может быть очень информативным и может снизить неопределенность системы при вычислении прогнозов

Стратегии обучения



Error Reduction (Стратегии уменьшения ошибок) пытаются выбрать элементы, сбор их оценок может напрямую уменьшить ошибку прогноза. Это связано с тем, что есть элементы с очень разными рейтингами, рейтинги которых плохо коррелируют с рейтингами других элементов. Стратегии уменьшения ошибок могут игнорировать эти элементы и уделять больше внимания элементам с рейтингами, которые могут положительно улучшить точность прогнозов.

Сокращение дисперсии

Идея: выбирать объекты, которые максимально сократят дисперсию.

$$MSE(b) = \frac{1}{n} \sum_{i=1}^n (y_i - f(x_i, b))^2$$

$$MSE(\hat{b}) = \min_b (MSE(b))$$

$$D[MSE(\hat{b})] \approx \left(\frac{\partial f(x)}{\partial b} \right)^T \left(\frac{\partial MSE(b)}{\partial b^2} \right)^{-1} \left(\frac{\partial f(x)}{\partial b} \right)$$

$$x = \arg \min_x D[MSE(\hat{b})]$$

Сокращение дисперсии

Идея: выбирать объекты, которые максимально сократят дисперсию.

$$MSE(b(x)) = \frac{1}{n} \sum_{i=1}^n (y_i - (b_1 x_i + b_2))^2$$

$$MSE(\hat{b}(x)) = \min_b (MSE(b(x)))$$

$$D[MSE(\hat{b})] \approx \left(\frac{\partial f(x)}{\partial b} \right)^T \left(\frac{\partial MSE(b)}{\partial b^2} \right)^{-1} \left(\frac{\partial f(x)}{\partial b} \right)$$

$$x = \arg \min_x D[MSE(\hat{b})]$$

Сокращение дисперсии

A-optimal: $\min \text{tr}(D[MSE(\hat{b})])$

D-optimal: $\min \det(D[MSE(\hat{b})])$

E-optimal: $\min_{\lambda} \max (D[MSE(\hat{b})])$ (по собственным значениям)

L-optimal: $\min \text{tr}$ от линейной комбинации объектов матрицы

Стратегии обучения



User adaptation (Стратегии адаптации пользователей) пытаются персонализировать процесс активного обучения в соответствии с конкретными характеристиками пользователей, выбирая и предлагая различные элементы для оценки разными пользователями. Это связано с тем, что разные пользователи могут иметь разные знания, знания и предпочтения по отношению к разным категориям элементов, и, следовательно, не очень удобно выбирать одинаковый набор элементов для этих разных типов пользователей. Соответственно, учет таких различий между пользователями в процессе активного обучения может привести к сбору более качественных и количественных оценок.

Стратегии обучения



Acquisition Probability (Стратегии вероятности приобретения) пытаются максимизировать вероятность того, что пользователь может оценить элемент, и, следовательно, они выбирают элементы, которые с большей вероятностью будут известны пользователю.

Стратегии обучения



Decision Tree-based (Стратегии, основанные на дереве решений) используют алгоритмы дерева решений для определения информативных элементов, которые должны быть выбраны для активного обучения. Каждый узел такого дерева решений содержит элемент-кандидат, который должен быть предложен новому пользователю для оценки. Таким образом, узел каким-то образом представляет группу пользователей-единомышленников, которые оценили этот кандидат аналогичным образом.

Стратегии обучения



Prediction based (Стратегии, основанные на прогнозировании) создают модели прогнозирования, которые используются для решения, какие элементы следует выбрать для активного обучения. Стратегии, основанные на прогнозировании, ранжируют элементы в соответствии с прогнозируемыми рейтингами и выбирают верхние элементы с наивысшими прогнозируемыми рейтингами.

Стратегии обучения



Hybrid (Гибридные стратегии) объединяют несколько отдельных стратегий, чтобы воспользоваться преимуществами нескольких. Это может позволить гибридным стратегиям одновременно оптимизировать различные показатели, такие как точность, разнообразие и удовлетворенность пользователей.

Вопросы

Полезные ссылки



- <http://active-learning.net/>
- https://github.com/SimiPixel/pool_based_active_learning
- Федоров В.В. (1971) Теория оптимального эксперимента (планирование регрессионных экспериментов)

Семинар: Разбор домашней работы №2

Uncertainty-based Active Learning

- Local manner

$$\hat{G}_{Uncertainty_{local}}(x_a) = -Uncertainty(Y_a)$$

- Global manner

$$\hat{G}_{Uncertainty_{local}}(x_a) = \frac{1}{|X^{(test)}|} \sum_{x \in X^{(test)}} \mathbb{E}_{T(a)}(Uncertainty(Y_x))$$