

Внедрение рекомендательных систем

План

1

Практические
аспекты внедрения
рекомендательных
систем

2

АБ-тесты

3

Многорукие
бандиты

4

Совмещение "тяжелых"
алгоритмов с онлайн
алгоритмами

5

Эвристики

Практические аспекты внедрения рекомендательных систем

План внедрения рекоменд. систем



1. Изучение продукта
2. Метрики
3. Нагрузки
4. Данные
5. Архитектура сервиса
6. Валидация
7. Алгоритмы

План внедрения рекоменд. систем



1. Изучение продукта
2. Метрики
3. Нагрузки
4. Данные
5. Архитектура сервиса
6. Валидация
7. Алгоритмы

Многорукые бандиты

Многорукие бандиты

Многорукий бандит (в теории вероятности) — это проблема, в которой фиксированный ограниченный набор ресурсов должен быть распределен между конкурирующими (альтернативными) вариантами так, чтобы это максимизировало ожидаемую выгоду. Свойства каждого выбора («ручки») известны только по наблюдению.



Многоручкие бандиты

Имеется $n \gg 1$ различных ручек. “Дергание” каждой ручки приносит нам некоторые, вообще говоря, случайные потери r (regret).

Цель: таким образом организовать процедуру дергания ручек (задается распределением вероятностей), чтобы ожидаемые суммарные потери после $N \gg 1$ дерганий (это число может быть заранее неизвестно!) были бы минимальны.

Проблема: никакой априорной информации о ручках у нас нет. Все, чем мы располагаем, это собственным опытом, полученным при дергании различных ручек (этого опыта нет на первом шаге).

Предположения: математическое ожидание потерь не зависит от случайности в предыстории, но может меняться от шага к шагу, “потери” по абсолютной величине ограничены числом \tilde{M} .

Многорукий бандит



Алгоритмы:

- Жадные (greedy) стратегии
- Upper Confidence Bound (UCB)
- Томпсоновское семплирование

Жадные (greedy) стратегии



Основная идея:

- Выбираем ручку, которая в среднем приносит наибольший выигрыш (доход)
- Проверяем другие ручки с вероятностью ϵ
- ϵ - может варьироваться или быть постоянной.

Upper Confidence Bound (UCB)

Основная идея:

- Выбираем ручку в соответствии с формулой:

$$\arg \max_{x_i} \left(E[\hat{r}(x_i)] + \sqrt{\frac{2 \ln n}{n_i}} \right),$$

где n – сколько всего раз мы дергали все «ручки», а n_i – сколько раз мы дергали i -ую ручку.

$\hat{r}(*)$ – оценка функции выигрыша (в общем случае случайная величина).

$\hat{r}(x_i)$ – значение выигрыша в точке x_i

Томпсоновское семплирование



Основная идея:

- Это байесовский подход!
- Для каждой ручки строится сопряженное распределение.
- Семплируем из распределения каждой ручки.
- Выбираем максимум.
- Получаем результаты – обновляем параметры сопряженных распределений.

На практике



1. Бандиты хороши с точки зрения математики.
2. Томпосновское семплирование дает лучший результат.
3. UCSB проигрывает, но не сильно.
4. Жадные стратегии самые неэффективные.

The background features a minimalist geometric design. A large white triangle occupies the upper-left and central portions of the frame. To its right, a black triangle points towards the top-right corner. The bottom-right corner is filled with a large red triangle. The text 'Instagram Explore' is positioned on the white background.

Instagram Explore

Instagram Explore



Instagram Explore – рекомендательная система Instagram, которая показывает рекламные объявления среди популярных публикаций и постов, соответствующих интересам пользователей.

Алгоритм Instagram Explore



Для поиска тематически схожих аккаунтов делается вывод о встраивании учетных записей, при использовании `ig2vec`, структуры встраивания, подобной `word2vec`. Как правило, фреймворк встраивания `word2vec` изучает представление слова на основе его контекста в предложениях в обучающем корпусе. `Ig2vec` обрабатывает идентификаторы учетных записей, с которыми взаимодействует пользователь - например, человек любит медиа из учетной записи - как последовательность слов в предложении.

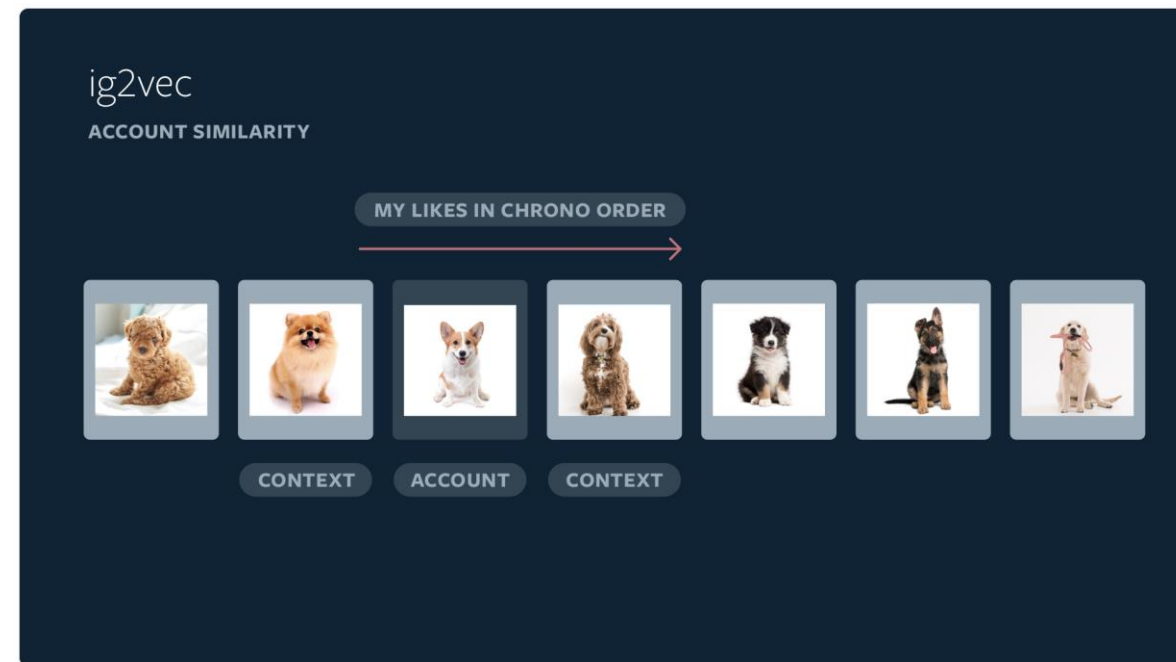
Алгоритм Instagram Explore



Применяя те же методы, что и word2vec, мы можем прогнозировать учетные записи, с которыми человек, вероятно, будет взаимодействовать в данном сеансе в приложении Instagram. Если человек взаимодействует с последовательностью учетных записей в одном сеансе, это с большей вероятностью будет тематически согласованным по сравнению со случайной последовательностью учетных записей из разнообразного диапазона учетных записей Instagram. Это помогает нам идентифицировать тематически похожие аккаунты.

Алгоритм Instagram Explore

Далее определяется показатель расстояния между двумя учетными записями - тот же, который используется при обучении внедрению, - который обычно представляет собой косинусное расстояние или точечное произведение. Исходя из этого, мы выполняем поиск в KNN, чтобы найти тематически похожие учетные записи для любой учетной записи во встраивании.



Алгоритм Instagram Explore



Чтобы иметь возможность максимизировать количество носителей для каждого запроса на ранжирование, Instagram ввел модель дистилляции ранжирования, которая помогает нам предварительно отбирать кандидатов перед использованием более сложных моделей ранжирования. Подход заключается в обучении сверхлегкой модели, которая учится и пытается максимально приблизиться к нашим основным моделям ранжирования.

Алгоритм Instagram Explore



После создания ключевых строительных блоков, необходимых для простого экспериментирования, эффективного определения интересов людей и создания эффективных и актуальных прогнозов, Instagram пришлось объединить эти системы вместе в производстве. Используя IGQL, встраивание учетных записей и технику дистилляции, системы рекомендаций Explore были разделены на два основных этапа:

- этап генерации кандидатов (также известный как этап поиска)
- этап ранжирования.

Алгоритм Instagram Explore



- Этап генерации кандидатов (также известный как этап поиска)

Для начала используются учетные записи, с которыми люди взаимодействовали раньше (например, ставили лайки или сохраняли медиафайлы из учетной записи) в Instagram, чтобы определить, какие другие учетные записи могут быть интересны людям. Затем используются методы встраивания учетных записей, чтобы идентифицировать учетные записи, похожие на исходные. Наконец, на основе этих учетных записей мы можем найти средства массовой информации, опубликованные в этих учетных записях или с которыми они взаимодействовали.

Алгоритм Instagram Explore

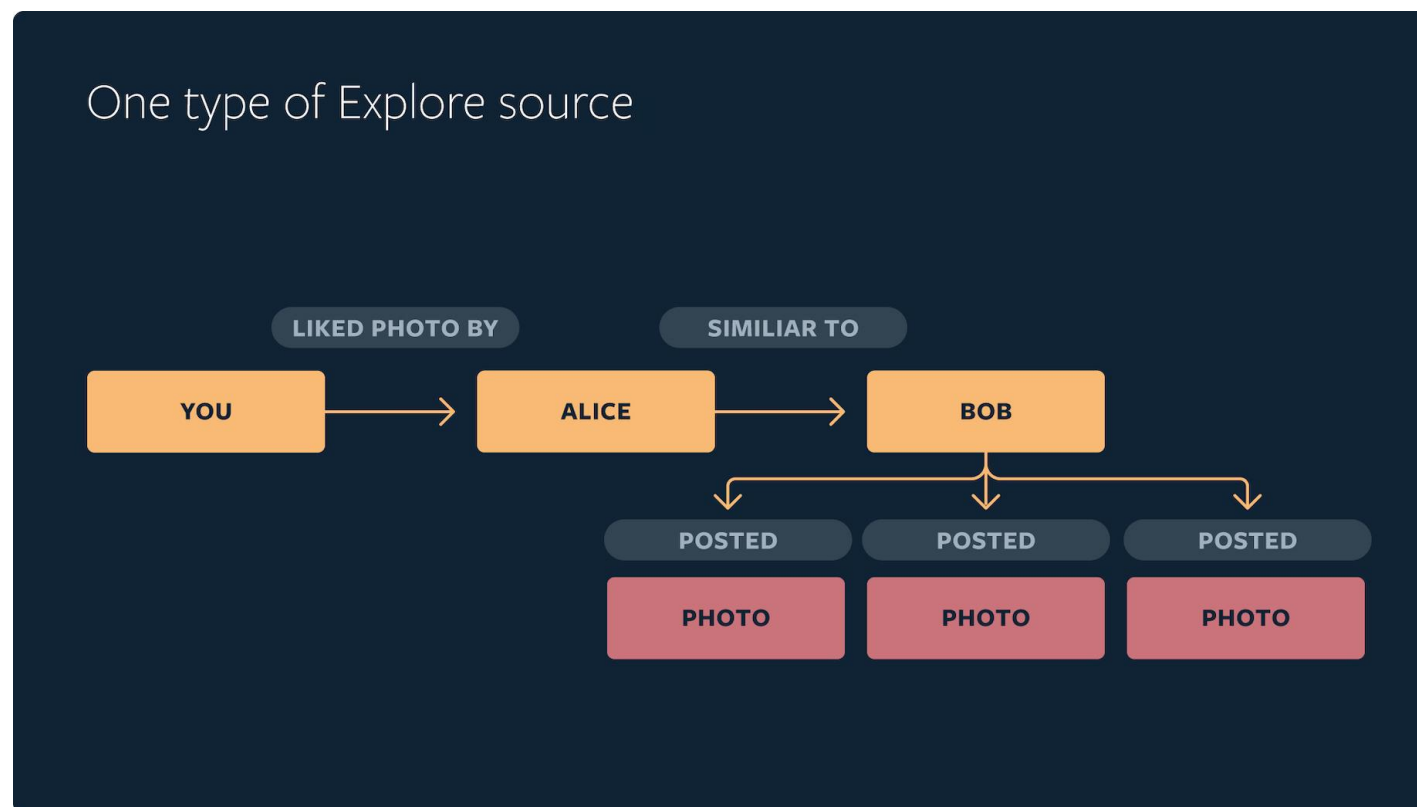


- Этап генерации кандидатов (также известный как этап поиска)

Для каждого запроса на ранжирование мы определяем тысячи подходящих СМИ для среднего человека, отбираем 500 кандидатов из подходящего инвентаря и затем отправляем кандидатов ниже по цепочке на этап ранжирования.

Алгоритм Instagram Explore

- Этап генерации кандидатов (также известный как этап поиска)



Алгоритм Instagram Explore



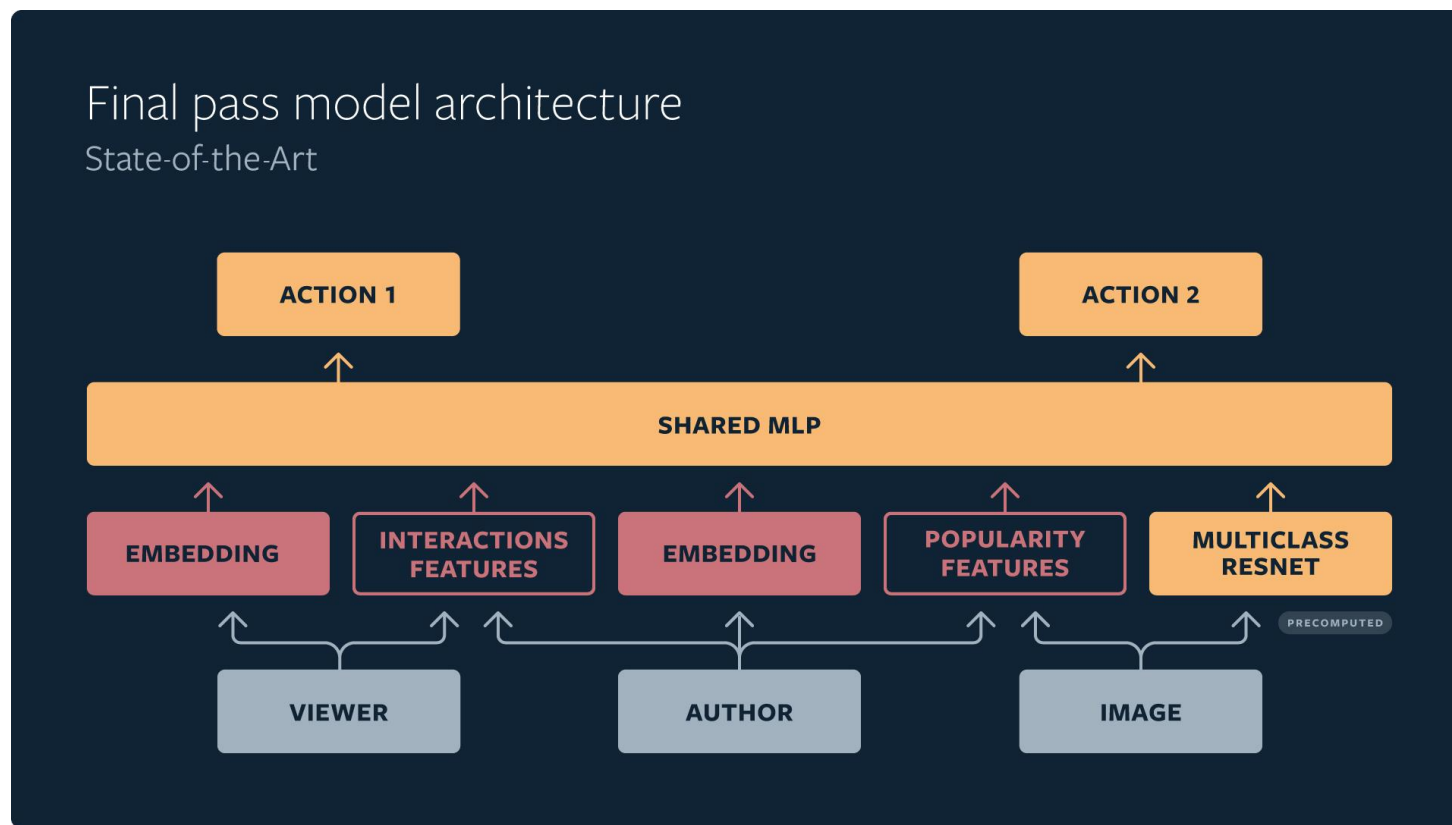
- Этап ранжирования

Имея 500 кандидатов, доступных для ранжирования, используется трехступенчатая инфраструктура ранжирования:

- Первый проход: модель дистилляции имитирует комбинацию двух других стадий с минимальными функциями; выбирает 150 наиболее качественных и наиболее подходящих кандидатов из 500.
- Второй этап: облегченная модель нейронной сети с полным набором фичей; выбирает 50 самых качественных и актуальных кандидатов.
- Последний этап: модель глубокой нейронной сети с полным набором фичей и эмбедингов. Выбирает 25 наиболее качественных и наиболее подходящих кандидатов (для первой страницы).

Алгоритм Instagram Explore

- Этап ранжирования



Совмещение "тяжелых" алгоритмов с онлайн алгоритмами

Товарные рекомендации



- Конверсия в заказ 1-2%
- Товаров больше 1 млн.
- Пользователей больше 1 млн. (из них 50% не авторизованы или новые)

Иерархия метрик: CTR (по рекомендательному блоку), конверсии.

Проблема: кликов много 😊, заказов мало ☹

Что делать?

Товарные рекомендации



- Конверсия в заказ 1-2%
- Товаров больше 1 млн.
- Пользователей больше 1 млн. (из них 50% не авторизованы или новые)

Иерархия метрик: CTR (по рекомендательному блоку), конверсии.

Проблема: кликов много 😊, заказов мало ☹

Что делать?

Разделение моделей



Модель «кластеризации» пользователей:

Пользователь, частота, категории

«Долгая» модель:

1. FM – как модель для эмбедингов
2. Нейронные сеть – как общая модель (может быть несколько на разные метрики или для разнообразия)
3. Отдельная модель для новичков (для каждой категории товаров)
4. Модель для AL-разметки
5. Агрегатор моделей

Разделение моделей



«Быстрые» модель:

1. Определение в какой категории клиент купит
2. Бандитские алгоритмы на общих выдачах и новичках.
 - Метрика - CTR
 - Метрика - продажи
 - Метрика – скроллы (переходы по страницам) как негативная

Модель балансировки «долгой» и «быстрой» с разными весами.

Пример

«Долгая» модель по считала листинг:

1. Арбуз – 4%
2. Банан – 3.2%
3. Апельсин – 3.1%
4. Томат – 3%
5. Груша – 2.5%
6. Тыква – 2%
7. Яблоко – 1%

В реальности:

1. Арбуз – 3% (3/100)
2. Банан – 4% (2/50)
3. Апельсин – 3% (3/100)
4. Томат – 0% (0/20)
5. Груша – 10% (1/10)
6. Тыква – 1% (1/100)
7. Яблоко – 20% (1/5)

Что делать? Показывать взвешенный листинг.

Эвристики и метрики

Эвристики



- Спросите у коллег
- Ручной матчинг
- «Топ товаров» в качестве подмешивания
- ...

Метрики



- Item Space Coverage
- User Space Coverage
- Новизна
- Нетривальность
- Доверие (trust)

Item Space Coverage



Чаще всего термин «покрытие» относится к той пропорции, которую может рекомендовать система рекомендаций. Это часто называют охватом каталога. Простейший показатель охвата каталога - это процент всех позиций, которые можно когда-либо рекомендовать. Эту меру можно вычислить во многих случаях непосредственно с учетом алгоритма и набора входных данных.

Item Space Coverage



Gini Index:

$$G = \frac{1}{n-1} \sum_{j=1}^n (2j - n - 1)p(i_j)$$

Shannon Entropy:

$$H = - \sum_{i=1}^n p(i) \log p(i)$$

User Space Coverage



Охват также может быть пропорцией пользователей или взаимодействий с пользователем, для которых система может рекомендовать элементы. Во многих приложениях рекомендатель может не давать рекомендаций для некоторых пользователей из-за, например, низкой уверенности в точности прогнозов для этого пользователя. В таких случаях мы можем предпочесть рекомендатели, которые могут предоставить рекомендации для более широкого круга пользователей. Очевидно, что такие рекомендации следует оценивать на основе компромисса между охватом и точностью.

Охват здесь можно измерить по разнообразию профиля пользователя, необходимого для вынесения рекомендации.